



Universidade do Minho  
Mestrado em Engenharia Informática

TRABALHO PRÁTICO DE MINERAÇÃO DE DADOS

---

# Titãs da indústria e a criptomoeda

---



PG47005  
Ana Teresa  
Gomes



PG49995  
Anabela  
Pereira



PG50219  
André  
Vieira



PG50460  
Joana  
Oliveira

## Conteúdo

<b>1</b>	<b>Introdução e Objetivos</b>	<b>2</b>
<b>2</b>	<b>Ideia inicial</b>	<b>3</b>
<b>3</b>	<b>Recolha e tratamento dos dados</b>	<b>3</b>
3.1	Bitcoin . . . . .	4
3.2	Dogecoin . . . . .	4
3.3	Tweets . . . . .	5
<b>4</b>	<b>Análise de Sentimentos</b>	<b>6</b>
4.1	Usando o GPT . . . . .	7
4.1.1	<i>app.py</i> . . . . .	7
4.1.2	<i>helper.py</i> . . . . .	7
4.2	Usando o BERT . . . . .	7
4.2.1	<i>app.bert.py</i> . . . . .	7
4.3	Usando NLTK . . . . .	8
4.3.1	<i>app_vader.py</i> . . . . .	8
<b>5</b>	<b>Análise de Resultados</b>	<b>8</b>
5.1	Bitcoin . . . . .	8
5.2	Dogecoin . . . . .	9
<b>6</b>	<b>Conclusões finais</b>	<b>10</b>
	<b>Appendices</b>	<b>11</b>
<b>A</b>	<b>Bitcoin</b>	<b>11</b>
A.1	GPT . . . . .	11
A.2	BERT - Laurens88 . . . . .	13
A.3	BERT - Svalabs . . . . .	15
A.4	BERT - Zainlaq7 . . . . .	17
A.5	NLTK . . . . .	19
<b>B</b>	<b>Dogecoin</b>	<b>21</b>
B.1	GPT . . . . .	21
B.2	BERT - Laurens88 . . . . .	23
B.3	BERT - Svalabs . . . . .	25
B.4	BERT - Zainlaq7 . . . . .	27
B.5	NLTK . . . . .	29

## 1 Introdução e Objetivos

Para este projeto da Unidade Curricular de Mineração de Dados, tem-se como objetivo avaliar o impacto dos *tweets* de Elon Musk na subida e descida das criptomoedas *Bitcoin* e *Dogecoin* por meio da análise de dados. Elon Musk, conhecido como um dos empresários mais influentes dos dias de hoje, possui uma presença relevante nas redes sociais, especialmente no *Twitter*, onde são partilhadas as suas opiniões e *insights* sobre diversos assuntos, incluindo o assunto do momento, as criptomoedas.

A escolha de Elon Musk como foco deste estudo é justificada pela sua grande influência na comunidade de investidores e entusiastas de criptomoedas. Deste modo, os seus *tweets* têm o poder de gerar grandes oscilações nos mercados financeiros, nomeadamente nos preços das criptomoedas, como já foi observado em ocasiões anteriores.

Neste projeto, utilizamos dados recolhidos de diferentes fontes, *CoinDesk*, *CoinGecko* e *Kaggle*, para construir um conjunto de dados abrangente, que abrange os *tweets* de Elon Musk relacionados à *Bitcoin*, *Dogecoin* e as respetivas variações de preço dessas criptomoedas. Com base nesses dados, aplicamos técnicas de mineração de dados e análise de sentimentos para identificar correlações entre os *tweets* de Musk e a subida e descida de preço da *Bitcoin* e *Dogecoin*.

Com base nos resultados obtidos a partir da análise dos dados, poderemos entender melhor a dinâmica do mercado de criptomoedas e fornecer informações úteis para investidores que desejam entender como as ações e palavras de Elon Musk podem afetar a valorização ou desvalorização da *Bitcoin* e *Dogecoin*.

## 2 Ideia inicial

Inicialmente, a nossa ideia para a realização deste projeto era tomar partido das vantagens da biblioteca *Tweepy*, que é amplamente utilizada para extrair dados da API do *Twitter*, a fim de obter os *tweets* de Elon Musk e, assim, conseguir-se um fluxo contínuo de *tweets* e suas respetivas informações, como data, hora e conteúdo.

Esta ideia não foi concretizada uma vez que, recentemente, o acesso às APIs do *Twitter* foi bloqueado para várias ferramentas, incluindo a *Tweepy*. Essa mudança na política de acesso impossibilitou a recolha direta dos *tweets* do Elon Musk, como se tinha inicialmente planeado.

Perante essa situação, adaptou-se a abordagem e optou-se por utilizar um *dataset* pré-existente contendo os *tweets* do Elon Musk, proveniente do *Kaggle*. Embora essa solução não nos permita acompanhar as publicações mais recentes, pode-se ainda realizar uma análise robusta e bastante completa com os dados disponíveis nesse mesmo *dataset*.

É importante destacar que, mesmo com essa limitação inesperada, estamos confiantes de que o projeto continua a ser de grande interesse, pois ainda assim os dados históricos são também bastante valiosos para identificar padrões e correlações entre os *tweets* de Musk e as variações do preço da *Bitcoin* e *Dogecoin*.

## 3 Recolha e tratamento dos dados

Neste capítulo, irá ser apresentada a metodologia utilizada para recolher e tratar os dados necessários para o nosso projeto.

Relativamente aos *tweets*, recorreu-se à plataforma *Kaggle*, que disponibiliza uma grande variedade de *datasets* com dados prontos para uso, e escolheu-se um *dataset* que continha um conjunto bastante abrangente de *tweets* de Elon Musk entre os anos de 2010 e 2021.

Quanto aos dados relacionados ao preço da *Bitcoin*, utilizamos a API da *CoinDesk*, uma das principais fontes de informações sobre criptomoedas, que nos fornece dados históricos e em tempo real sobre o preço da *Bitcoin*. Quanto à *Dogecoin*, obteve-se os dados a partir da API da *CoinGecko*, também uma fonte de informações bastante importante na área das criptomoedas.

Após a obtenção dos dados em estado bruto, realizou-se um processo de tratamento dos mesmos, que vai ser explicado agora à frente.

### 3.1 Bitcoin

Para a recolha dos dados relativamente à criptomoeda, recorreu-se à biblioteca *requests*, de modo a ter-se acesso à API *CoinDesk*. Na URL utilizada, forneceu-se a data de início e de fim como parâmetros, para que os dados provenientes da API sejam apenas os correspondentes às datas desejadas.

Após recebido o ficheiro JSON que consiste na resposta da API, extraíram-se os dados e com estes criou-se a coluna 'bitcoin\_price', que representa o preço do *Bitcoin* em cada uma das datas.

Criou-se também uma coluna chamada 'stonks', inicializada com o valor 0. Os dados dessa coluna são obtidos através da comparação do preço atual do *Bitcoin* com o preço anterior, ou seja, se o preço atual for menor que o preço anterior, atribuímos o valor -1 à coluna 'stonks', indicando uma queda. Se o preço atual for maior que o preço anterior, atribuímos o valor 1, indicando um aumento.

Por fim, guarda-se num ficheiro CSV com nome de 'bitcoin.csv'. Em seguida, mostra-se uma linha do dataset em que a coluna 'date' corresponde a uma data específica:

	<b>date</b>	<b>bitcoin_price</b>	<b>stonks</b>
4123	2021-11-01	61338.5317	-1

Figura 1:

### 3.2 Dogecoin

Para além da *Bitcoin*, decidiu-se explorar também os resultados para outra criptomoeda, a *Dogecoin*. Fez-se uma recolha e tratamento dos dados muito semelhante ao anteriormente mencionado para a *Bitcoin*, no entanto usando a API *CoinGecko*, e criando as colunas 'dogecoin\_price' e 'stonks'.

Em seguida, também se mostra uma linha do *dataset* em que a coluna 'date' corresponde a uma data específica:

	<b>date</b>	<b>dogecoin_price</b>	<b>stonks</b>
4123	2021-11-01	61338.5317	-1

Figura 2:

### 3.3 Tweets

Inicialmente, concatenamos todos os arquivos CSV que contém os *tweets* referentes a cada ano, respectivamente, num único *dataset*, agrupando-os por ano. Essa consolidação permitiu uma visão mais abrangente dos *tweets* ao longo do tempo e facilitou a análise e a manipulação dos dados.

De seguida, nesse *dataset* concatenado, é feita a remoção de linhas duplicadas, redefinição do índice e, ainda, a exclusão de colunas não relevantes para o estudo, ou seja, exclui-se todas exceto a data e o conteúdo do *tweet*. Note-se que a coluna da data foi convertida para o formato ano-mês-dia, facilitando assim a análise temporal dos vários *tweets*.

	<b>date</b>	<b>tweet</b>
<b>0</b>	2010-06-04	Please ignore prior tweets, as that was someon...
<b>1</b>	2011-12-28	@TheOnion So true :)
<b>2</b>	2011-12-27	If you ever wanted to know the *real* truth ab...
<b>3</b>	2011-12-26	Walked around a neighborhood recently rebuilt ...
<b>4</b>	2011-12-26	It was Xmas, so we brought presents for the ki...
...	...	...
<b>34356</b>	2022-01-03	@jack Reminds me of when I hex edited Ultima V...
<b>34357</b>	2022-01-03	@ClaudioOmbrella @Tesla @slcuervo @alex_avoigt...
<b>34358</b>	2022-01-03	@auren There is no way to be in touch with vot...
<b>34360</b>	2022-01-02	Let's make the roaring 20's happen!
<b>34361</b>	2022-01-02	Great work by Tesla team worldwide!

13834 rows × 2 columns

Figura 3:

Posteriormente, identificamos a necessidade de limpar as menções a utilizadores e URLs presentes nos *tweets* e, para isso, utilizamos expressões regulares de forma a encontrar e remover esses mesmos elementos indesejados. Essa remoção é feita através da função *clean\_tweet*, que substitui as menções e URLs encontrados nos *tweets* por strings vazias.

Ainda relativamente à limpeza dos dados, considerou-se importante também converter todos os caracteres para minúsculas, remover espaços extras no início e no final das strings e entre as palavras, substituindo-os por um único espaço, e remover qualquer pontuação presente. Assim, obtemos o seguinte:

	<b>date</b>	<b>tweet</b>	<b>clean_tweet</b>
0	2010-06-04	Please ignore prior tweets, as that was someone...	please ignore prior tweets as that was someon...
25	2011-12-01	Went to Iceland on Sat to ride bumper cars on ...	went to iceland on sat to ride bumper cars on ...
24	2011-12-01	I made the volume on the Model S go to 11. ...	i made the volume on the model s go to 11 now...
23	2011-12-03	Great Voltaire quote, arguably better than Twa...	great voltaire quote arguably better than twa...
22	2011-12-03	That was a total non sequitur btw	that was a total non sequitur btw
...	...	...	...
13441	2022-03-05	Obviously, this would negatively affect Tesla,...	obviously this would negatively affect tesla ...
13443	2022-03-05	Haha sure :)	haha sure
13430	2022-03-05	In a way, this is free QA haha	in a way this is free qa haha
13438	2022-03-05	Exactly	exactly
13431	2022-03-05	A beautiful home for life	a beautiful home for life

13834 rows × 3 columns

Figura 4:

Terminada a limpeza dos dados, passa-se agora para filtrar apenas aqueles que nos interessam para o estudo através de uma lista de palavras-chave, de modo a que se consiga obter um novo *dataset* que contenha apenas os *tweets* relevantes, isto é, aqueles que contêm pelo menos uma das palavras-chave especificadas na lista.

## 4 Análise de Sentimentos

A análise de sentimentos é uma técnica que nos permite estudar as emoções e opiniões expressas em textos, no caso de Elon Musk, em forma de *tweet*. Assim, ao aplicar a análise de sentimentos aos *tweets*, pode-se obter *insights* importantes sobre a influência de Musk no mercado da criptomoeda.

Exemplificando, iremos estudar se o facto da análise de sentimentos num determinado período de tempo revelar que os *tweets* de Musk sobre a criptomoeda tem um sentimento positivo, implica que as suas declarações estejam associadas a um aumento no valor da criptomoeda nesse período de tempo. Pelo contrário, estudar também se o facto da análise mostrar um sentimento negativo, se pode deduzir que os *tweets* de Musk estão a contribuir para uma quebra no valor da criptomoeda nesse período de tempo.

Para efetuar essa análise, usamos modelos da OpenAI, BERT e NLTK, de forma a podermos comparar resultados.

## 4.1 Usando o GPT

### 4.1.1 *app.py*

Primeiro, carregou-se os *tweets* resultantes do tratamento e da limpeza feitos anteriormente ('only\_clean\_tweets.csv'). Tendo os *tweets* carregados, dividiu-se o dataset em vários subconjuntos com o objetivo de garantir que o tamanho dos *tweets* seja adequado para a análise, ou seja, cada subconjunto apresenta um tamanho total dos caracteres que não excede os 2000.

De seguida, criou-se um comando de análise de sentimentos (*prompt*). O *prompt* descreve como é desejada que seja feita a análise de sentimentos aos *tweets* do Elon Musk relativamente à criptomoeda. Também são incluídas algumas frases de exemplo de modo a ilustrar a resposta esperada do modelo.

Assim, com o *prompt* desenvolvido, percorre-se cada subconjunto de *tweets* e aplica-se a função 'analise\_sentimento' de modo a obter esta análise para cada um dos subconjuntos de *tweets*. A função retorna a resposta em ficheiro JSON, que consiste numa lista de análises de sentimentos aos respetivos *tweets*.

### 4.1.2 *helper.py*

Aqui, tem-se as funções auxiliares utilizadas em *app.py*. Primeiramente, é feita a divisão do conjunto de dados em subconjuntos mais reduzidos, garantindo assim que o tamanho total dos caracteres de cada subconjunto não excede o limite fornecido. Depois, uma lista de strings é transformada numa única string. Finalmente, efetua-se a análise de sentimentos utilizando a API da OpenAI, que recebe o texto a ser analisado e o *prompt*. É feita uma chamada à API e recebe-se a resposta contendo o resultado da análise, que é guardada num arquivo JSON.

## 4.2 Usando o BERT

### 4.2.1 *app\_bert.py*

Primeiro, carrega-se também o ficheiro csv 'only\_clean\_tweets.csv'. Depois, tem-se a configuração do modelo, onde são apenas definidos três possíveis sentimentos (positivo, negativo neutro), e do *tokenizer*, onde os *tweets* são dados como entrada e este retorna os *tokens* correspondentes todos com o mesmo tamanho.

Finalmente, são obtidos os vários sentimentos previstos a partir do modelo.

## 4.3 Usando NLTK

### 4.3.1 app\_vader.py

Depois de também se carregar o ficheiro csv 'only\_clean\_tweets.csv', é aplicada a análise de sentimento nos *tweets* utilizando o modelo de *sentiment analysis* da NLTK.

Posteriormente, são atribuídos sentimentos aos *tweets* com base numa "pontuação" retornada por esse analisador, ou seja, se estivermos perante valores  $i = 0.05$ , o *tweet* é classificado como "POSITIVO", se for  $i = -0.05$ , é classificado como "NEGATIVO" e, caso contrário, é classificado como "NEUTRO".

## 5 Análise de Resultados

Numa análise geral dos resultados obtidos através do diversos modelos, é de notar que a classificação dos sentimentos dos *tweets* feita pela API da openAI é a que apresenta menor número de *tweets* classificados como '*NEGATIVE*', com apenas 6.1%, e o com mais *tweets* com esta classificação é o modelo de *sentiment analysis* da NLTK, com 19.9%. Em relação à *label* de '*POSITIVE*' o modelo do BERT é o que apresenta menor percentagem desta *label*, com 31.6%, e o modelo da NLTK que apresenta maior, com 49.2%.

O resultados de superioridade de *labels*, tanto negativas como positivas, no modelo da NLTK devem-se ao facto de este modelo, ao contrário dos modelos do BERT e do GPT utilizados, não ser treinado especificamente para o caso de criptomoedas. Foi utilizado também um modelo de classificação de sentimentos binária de forma a ver se haveria uma melhor relação com subidas e/ou descidas dos valores das criptomoedas em análise.

Toda esta análise de resultados foi realizada através dos gráficos presentes nos *notebooks* *graficosDogecoin* e *graficosBitcoin*. Estes gráficos encontram-se disponíveis no documento em apêndice.

### 5.1 Bitcoin

No caso da *Bitcoin*, o modelo que mais se aproximou de dizer que o *tweet* é '*positive*' / '*negative*' e na proximidade dessa data o preço da *Bitcoin* ter subido/descido foi o modelo *text-davinci-003* da openAI. Apesar de ao longo do tempo haverem *tweets* classificados como positivos/negativos e não interferir no preço da *Bitcoin*, o grupo considerou-os como *outliers* e tem-se em conta que existem inúmeros fatores que influenciam o preço das criptomoedas.

## 5.2 Dogecoin

Para se ter um termo de comparação com a *Bitcoin*, decidiu-se avaliar o preço da *Dogecoin*, visto que Elon Musk menciona ao longo do tempo várias vezes esta criptomoeda.

Desta forma, seguiu-se a mesma linha de raciocínio para a criptomoeda anterior e, uma vez mais, o melhor modelo foi o da openAI. O *prompt* foi ligeiramente diferente do anterior, pois foi adaptado para a *Dogecoin*.

Entre 2021 e 2022, existiu um pico bastante elevado no valor da *Dogecoin* na altura em que o Elon Musk fez mais *tweets* considerados positivos em relação à criptomoeda.

## 6 Conclusões finais

Primeiramente, este projeto teve o intuito de analisar o impacto dos *tweets* de Elon Musk, uma grande personalidade do mundo da indústria, em duas das várias criptomoedas existentes, a *Bitcoin* e a *Dogecoin*.

Através da utilização de diferentes modelos de análise de sentimentos, que são eles o GPT, BERT e NLTK, pudemos obter resultados mais robustos e mais aproximados da realidade. Estes forneceram-nos *insights* valiosos sobre a polaridade dos *tweets*, isto é, se são de caráter positivo ou negativo, e tiveram uma enorme importância a identificar tendências de sentimento em relação às duas criptomoedas estudadas.

Foi observado que, em muitos dos casos, quando Elon Musk efetuava uma menção positiva a uma dessas moedas num determinado espaço de tempo, a respetiva criptomoeda de facto tendia a ter uma valorização no mercado durante esse mesmo espaço temporal. No entanto, é importante ressaltar que essa relação nem sempre se concretiza, provavelmente devido ao facto de existirem muitos fatores externos que também influenciam bastante este mercado das criptomoedas.

Como trabalho futuro, seria necessária uma procura mais aprofundada de *tweets* previamente *labelled* para ser possível treinar mais modelos, visto que, os modelos usados já eram todos pré-treinados. A introdução de informação acerca da variação do preço de outras criptomoedas não será de grande relevância, uma vez que a mais referida e influente é a *Bitcoin*. No entanto, é de notar que a introdução de novos dados sobre o preço das criptomoedas utilizadas neste projeto é, por outro lado, encorajada.

Em suma, este estudo permitiu-nos explorar a relação entre os *tweets* de Elon Musk e as criptomoedas *Bitcoin* e *Dogecoin*. Concluímos que sua influência pode de facto ter um impacto grande na valorização ou desvalorização das moedas, ainda que seja necessário considerar uma série de fatores externos de forma a estar completamente a par das flutuações do mercado. A utilização de modelos como GPT, BERT e NLTK na análise de sentimentos contribuiu para uma avaliação mais precisa e refinada dos resultados.

# Appendices

## A Bitcoin

### A.1 GPT

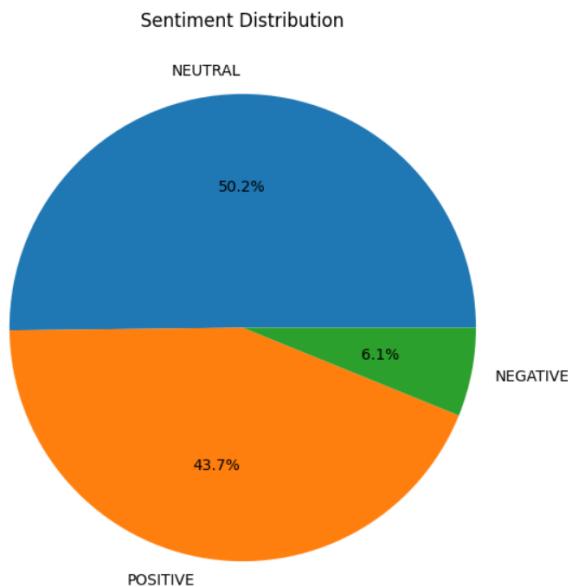


Figura 5: Distribuição de Sentimentos

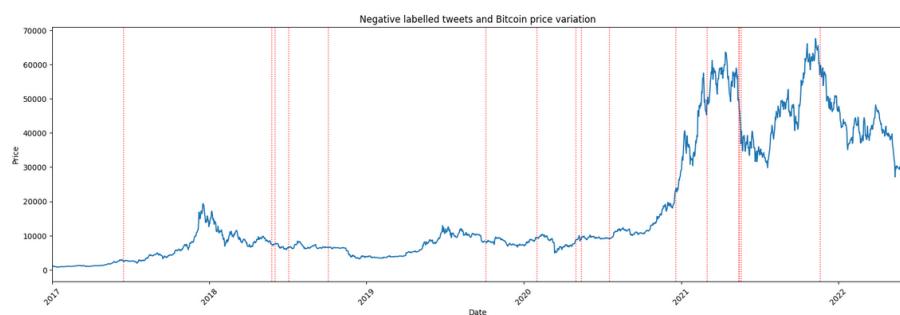


Figura 6: Relação entre *tweets* classificados como negativos e a variação do preço da Bitcoin

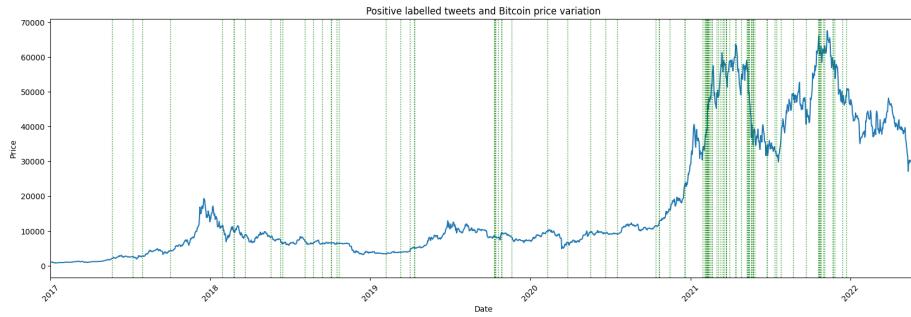


Figura 7: Relação entre *tweets* classificados como positivos e a variação do preço da Bitcoin

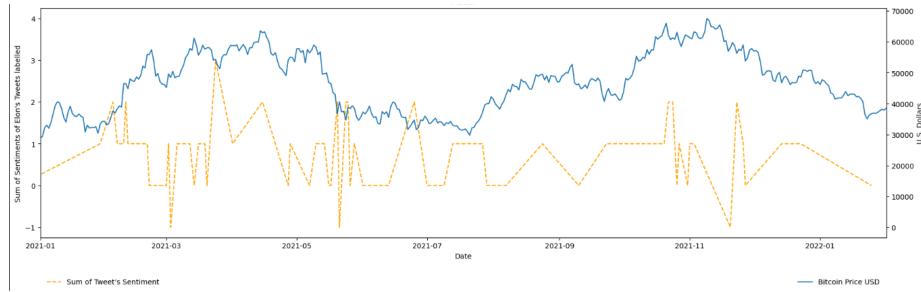


Figura 8: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Bitcoin



Figura 9: Distribuição positiva e negativa dos diferentes termos

## A.2 BERT - Laurens88

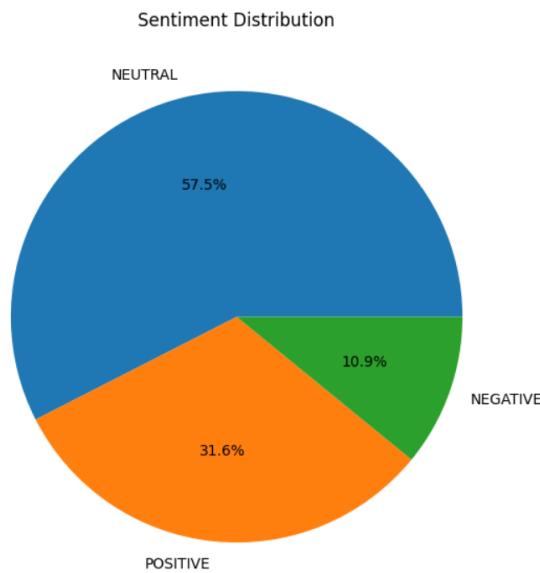


Figura 10: Distribuição de Sentimentos

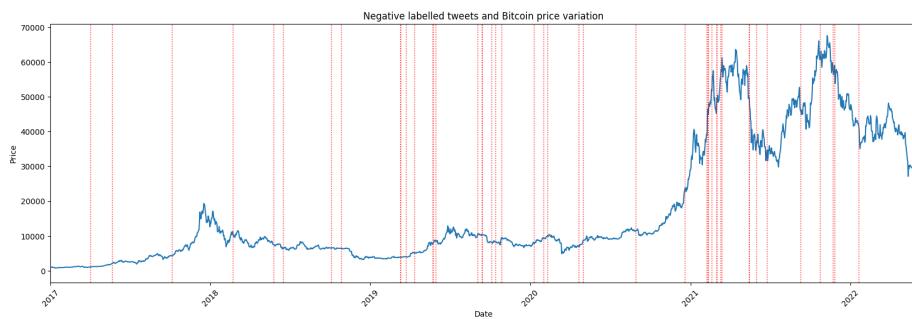


Figura 11: Relação entre *tweets* classificados como negativos e a variação do preço da Bitcoin

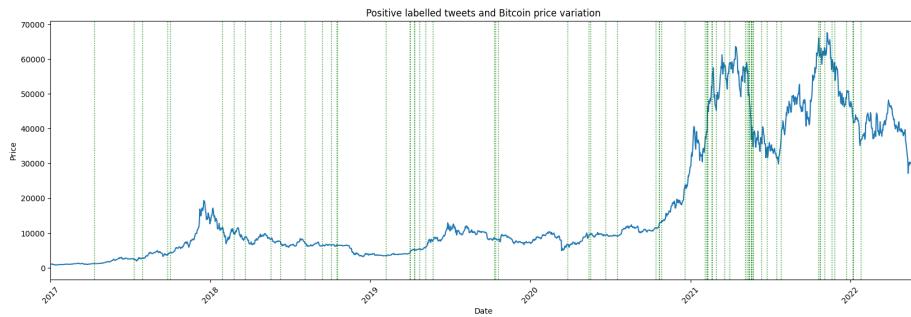


Figura 12: Relação entre tweets classificados como positivos e a variação do preço da Bitcoin

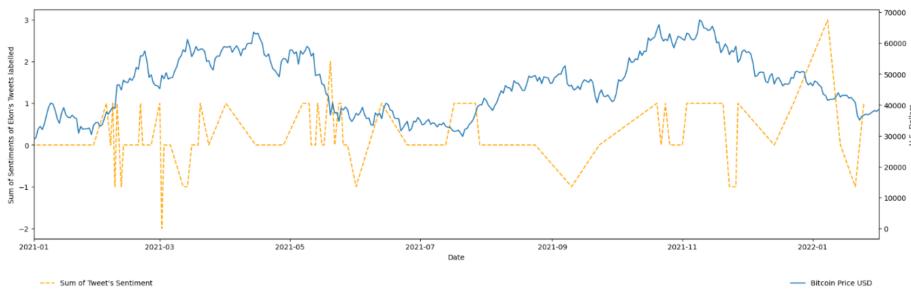


Figura 13: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Bitcoin



Figura 14: Distribuição positiva e negativa dos diferentes termos

### A.3 BERT - Svalabs

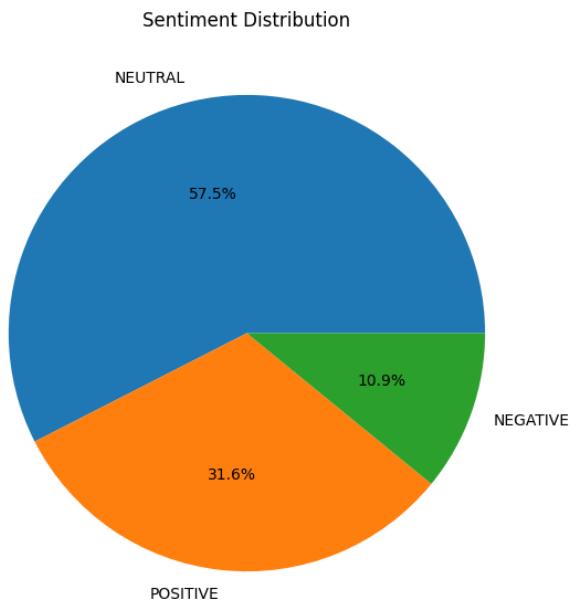


Figura 15: Distribuição de Sentimentos

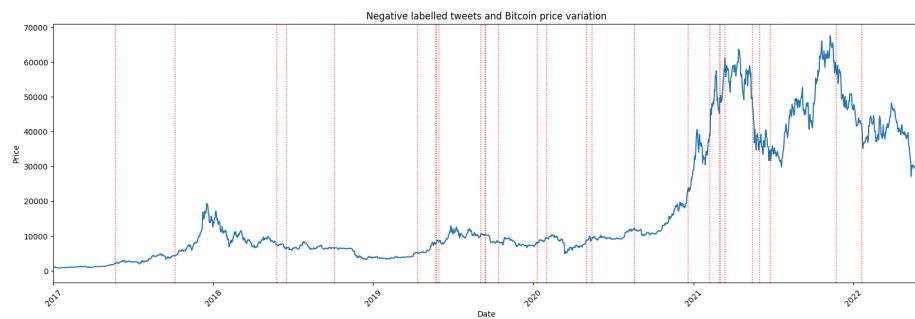


Figura 16: Relação entre *tweets* classificados como negativos e a variação do preço da Bitcoin

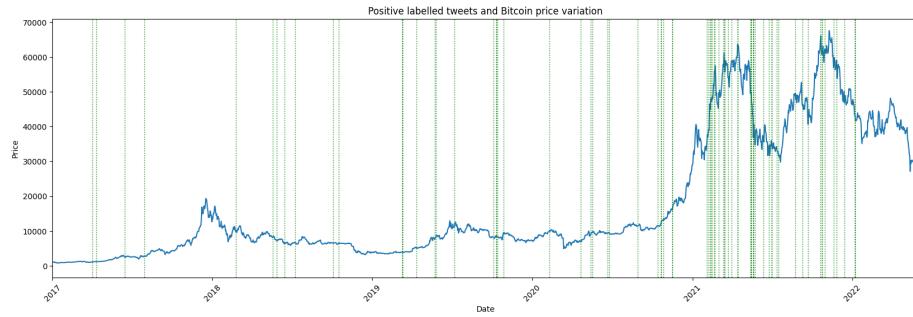


Figura 17: Relação entre tweets classificados como positivos e a variação do preço da Bitcoin

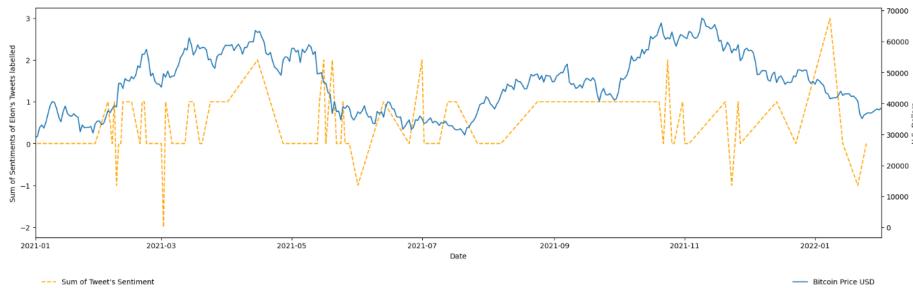


Figura 18: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Bitcoin



Figura 19: Distribuição positiva e negativa dos diferentes termos

#### A.4 BERT - Zainlaq7

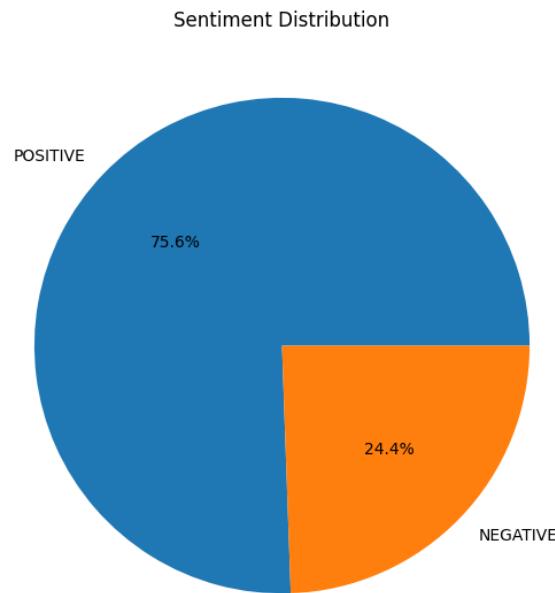


Figura 20: Distribuição de Sentimentos

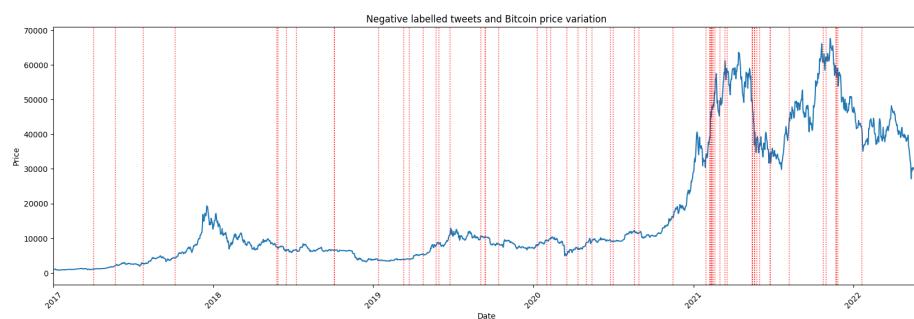


Figura 21: Relação entre *tweets* classificados como negativos e a variação do preço da Bitcoin

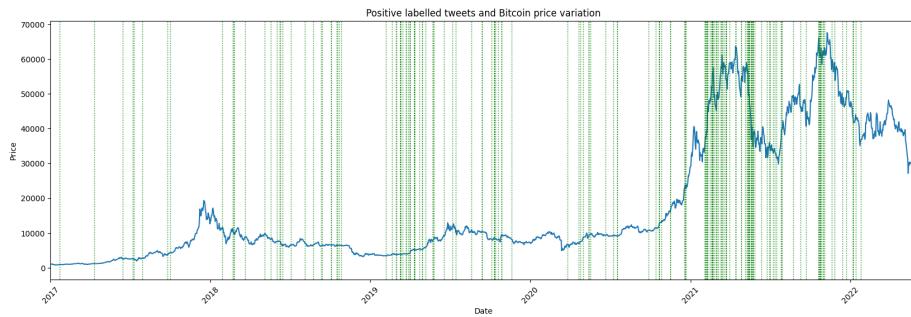


Figura 22: Relação entre tweets classificados como positivos e a variação do preço da Bitcoin

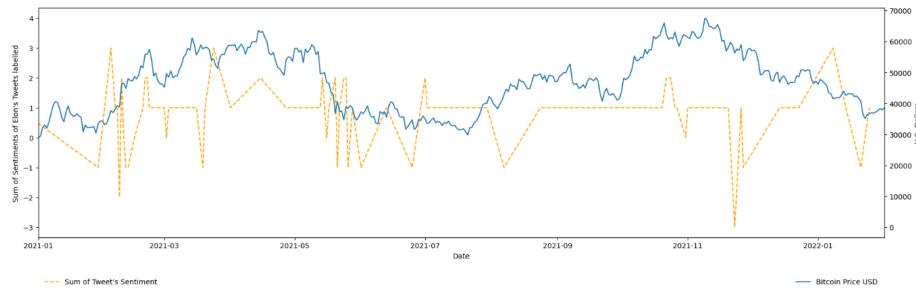


Figura 23: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Bitcoin



Figura 24: Distribuição positiva e negativa dos diferentes termos

### A.5 NLTK

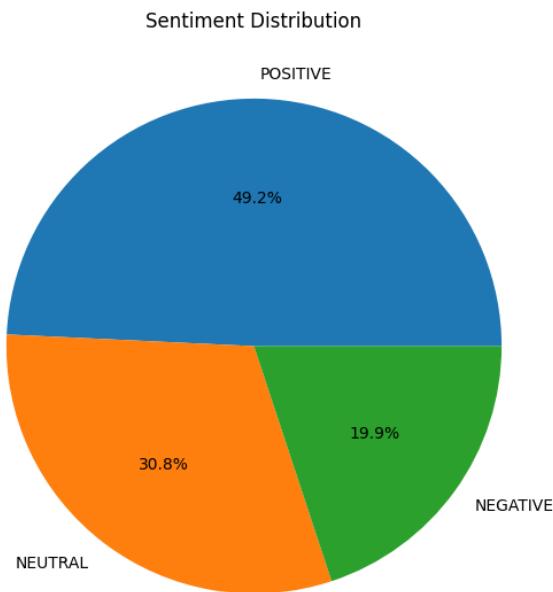


Figura 25: Distribuição de Sentimentos

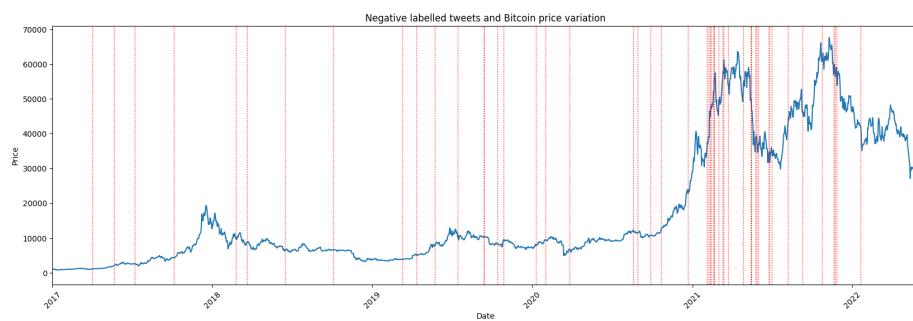


Figura 26: Relação entre *tweets* classificados como negativos e a variação do preço da Bitcoin

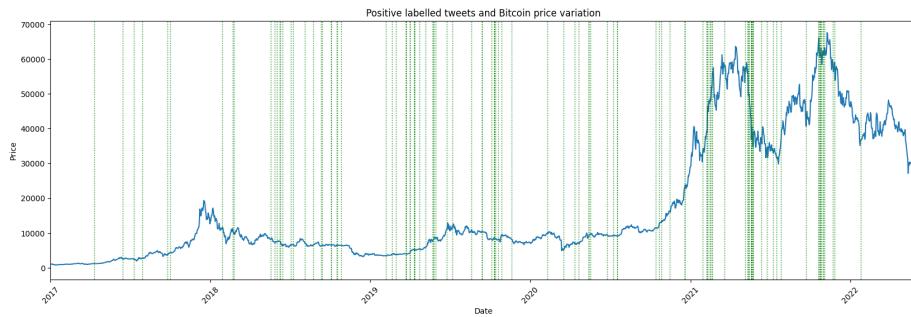


Figura 27: Relação entre tweets classificados como positivos e a variação do preço da Bitcoin

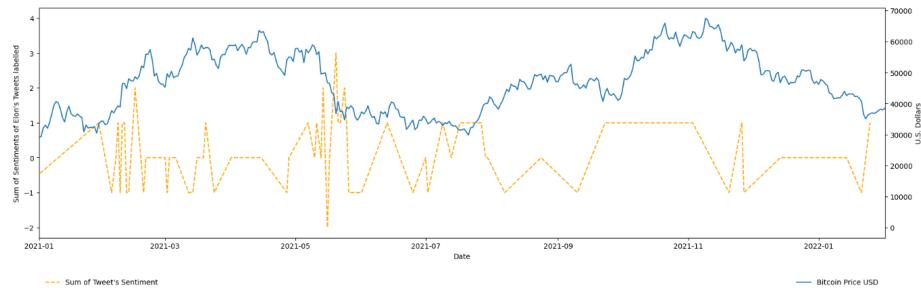


Figura 28: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Bitcoin



Figura 29: Distribuição positiva e negativa dos diferentes termos

## B Dogecoin

### B.1 GPT

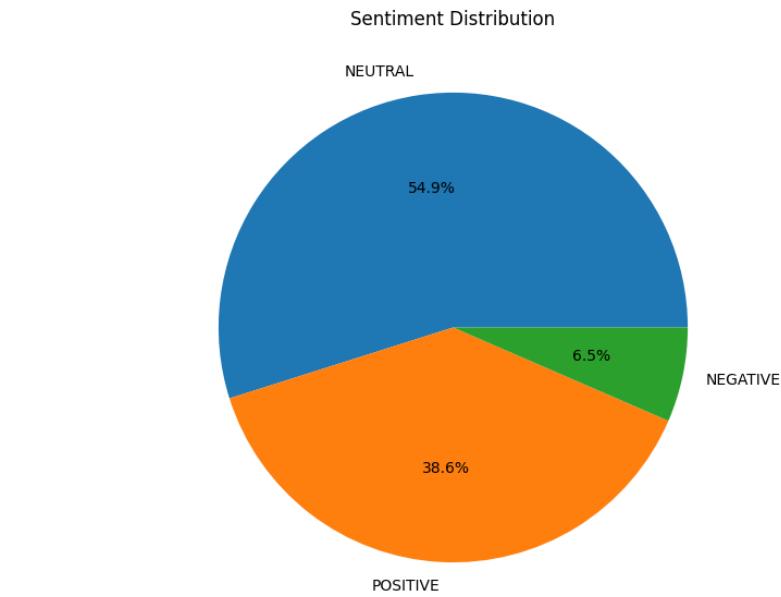


Figura 30: Distribuição de Sentimentos

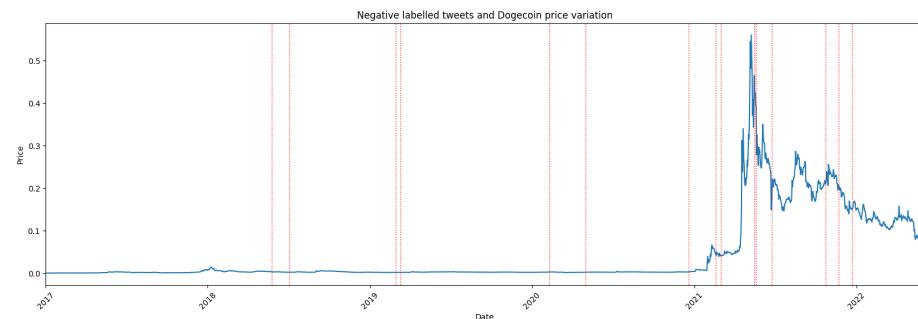


Figura 31: Relação entre *tweets* classificados como negativos e a variação do preço da Dogecoin

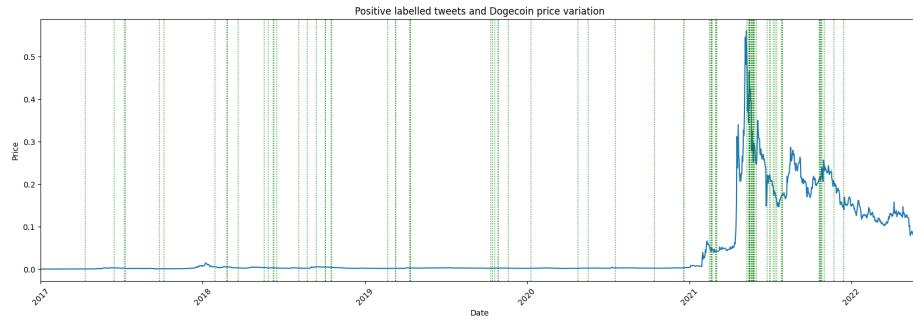


Figura 32: Relação entre *tweets* classificados como positivos e a variação do preço da Dogecoin

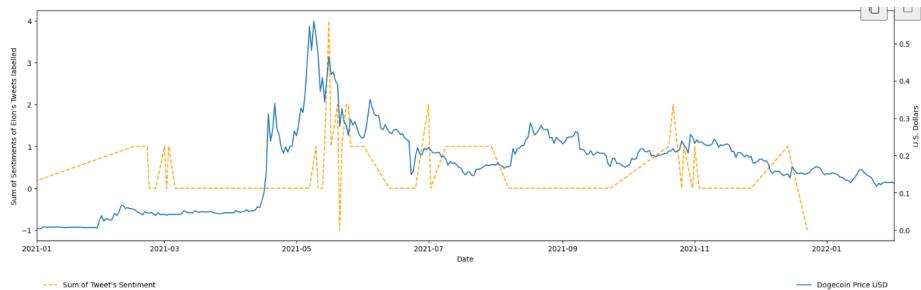


Figura 33: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Dogecoin



Figura 34: Distribuição positiva e negativa dos diferentes termos

## B.2 BERT - Laurens88

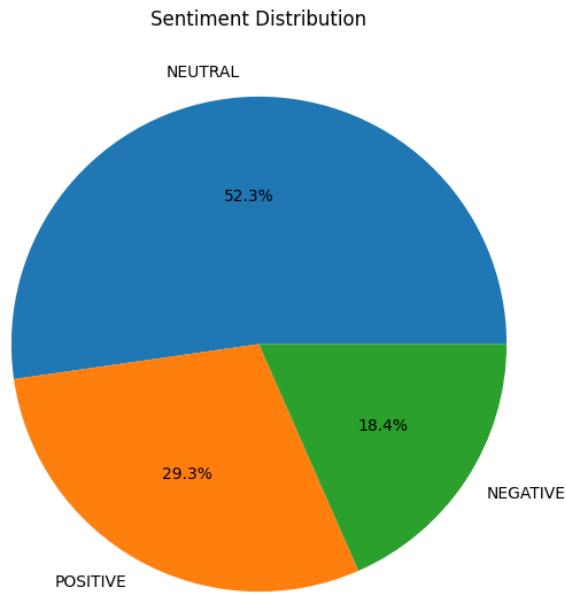


Figura 35: Distribuição de Sentimentos

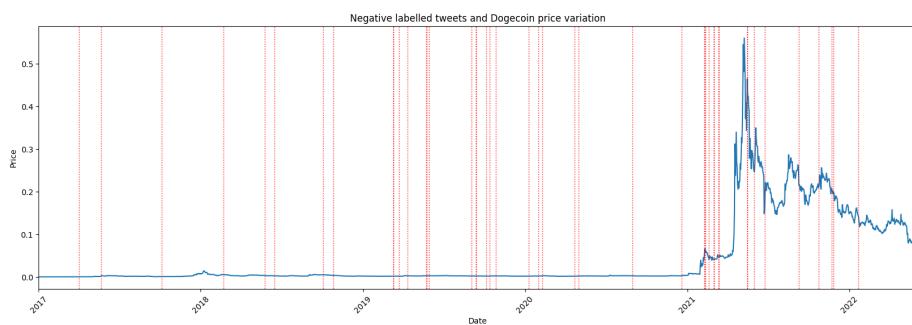


Figura 36: Relação entre *tweets* classificados como negativos e a variação do preço da Dogecoin

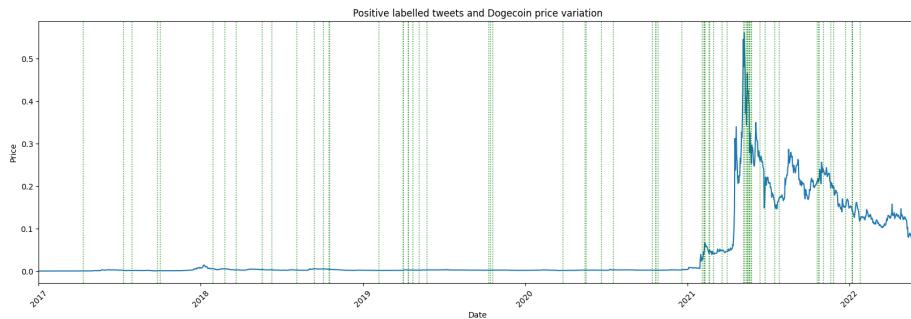


Figura 37: Relação entre tweets classificados como positivos e a variação do preço da Dogecoin

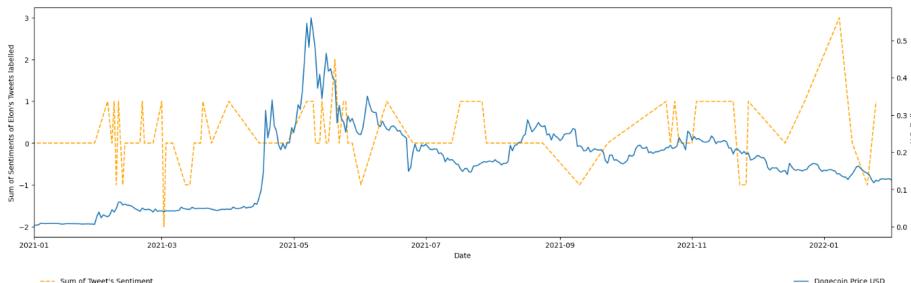


Figura 38: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Dogecoin



Figura 39: Distribuição positiva e negativa dos diferentes termos

### B.3 BERT - Svalabs

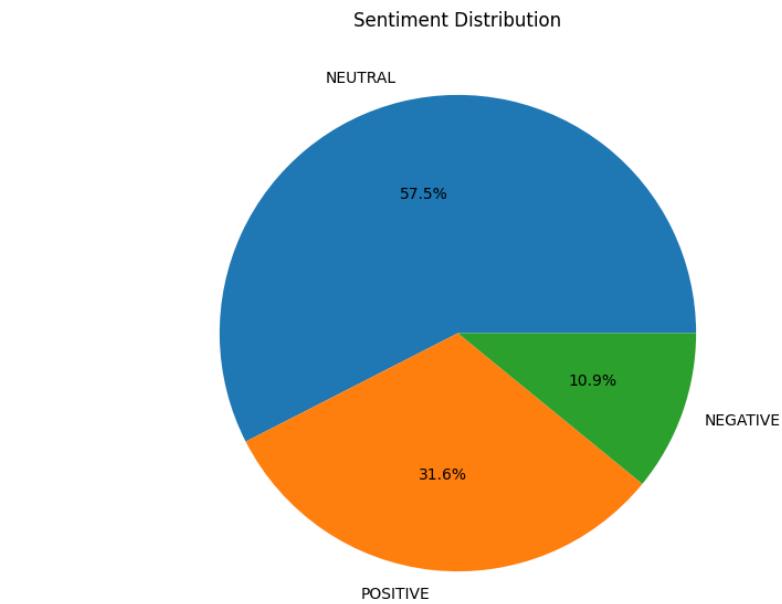


Figura 40: Distribuição de Sentimentos

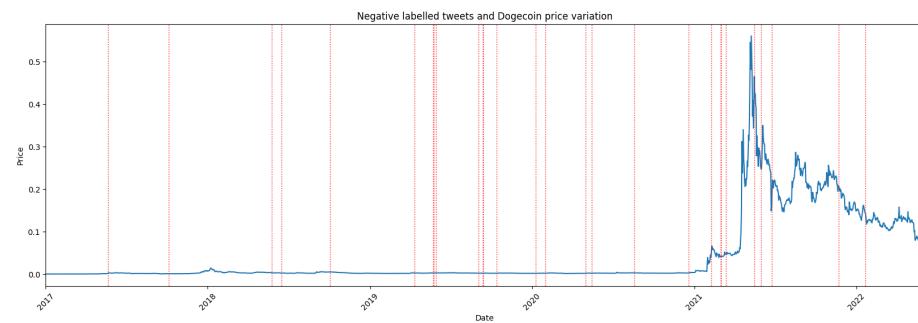


Figura 41: Relação entre *tweets* classificados como negativos e a variação do preço da Dogecoin

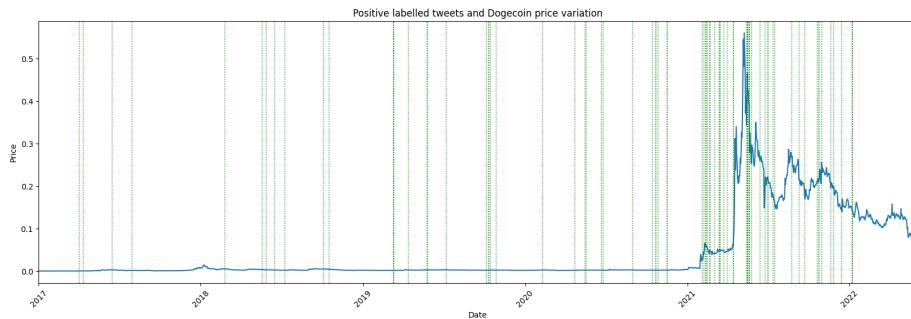


Figura 42: Relação entre *tweets* classificados como positivos e a variação do preço da Dogecoin

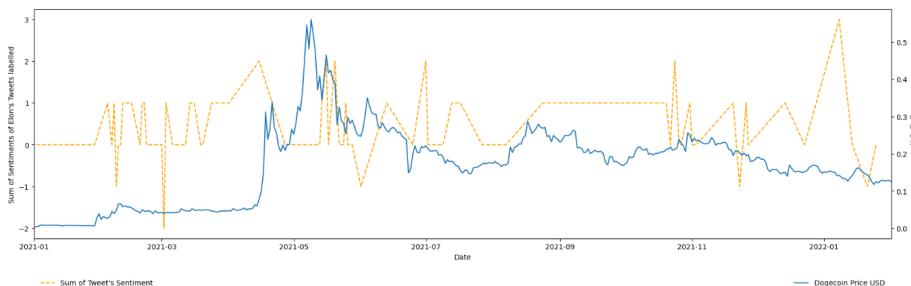


Figura 43: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Dogecoin



Figura 44: Distribuição positiva e negativa dos diferentes termos

#### B.4 BERT - Zainlaq7

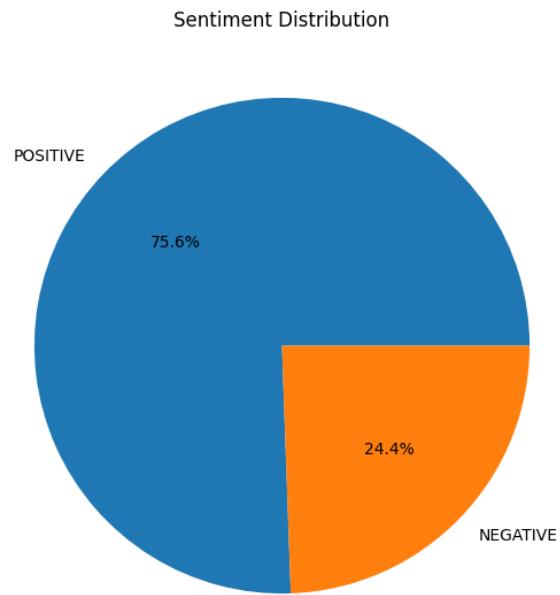


Figura 45: Distribuição de Sentimentos

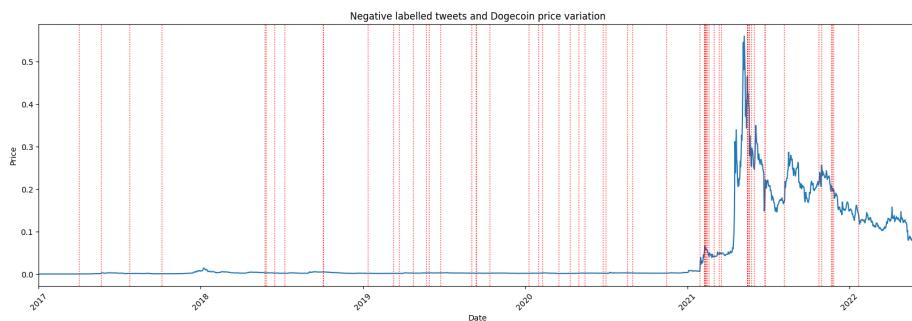


Figura 46: Relação entre *tweets* classificados como negativos e a variação do preço da Dogecoin

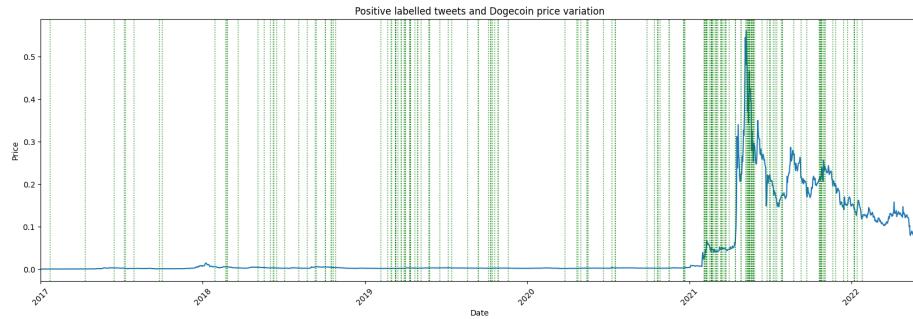


Figura 47: Relação entre *tweets* classificados como positivos e a variação do preço da Dogecoin

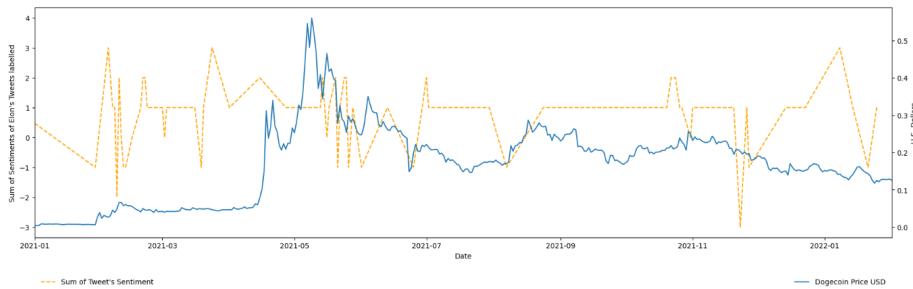


Figura 48: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Dogecoin

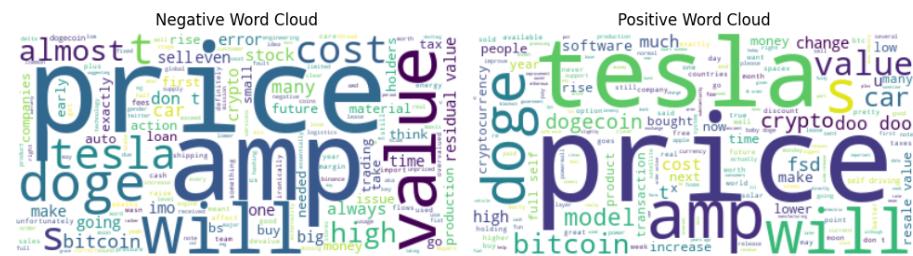


Figura 49: Distribuição positiva e negativa dos diferentes termos

## B.5 NLTK

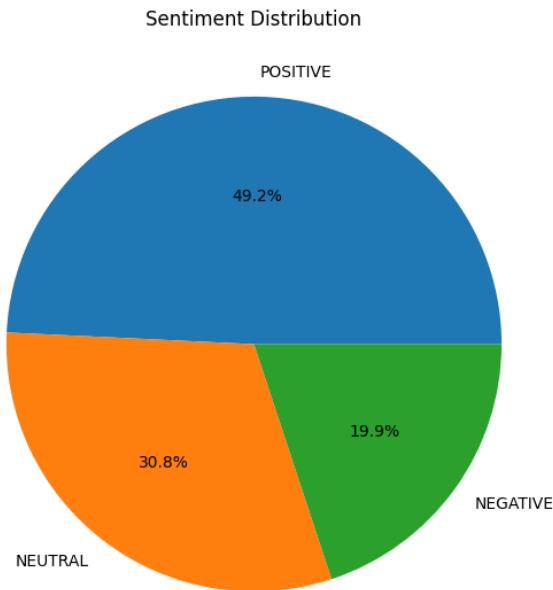


Figura 50: Distribuição de Sentimentos

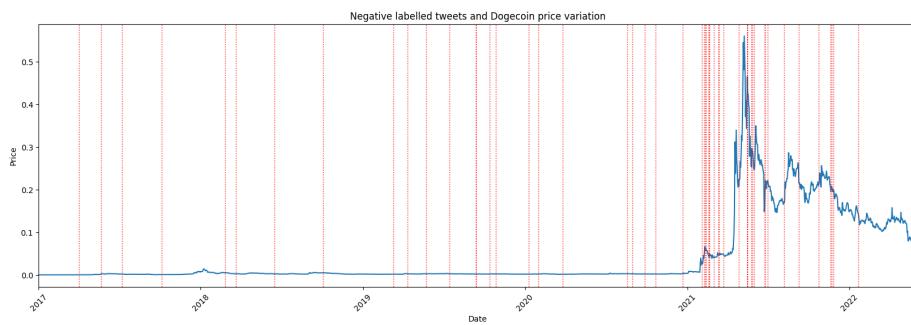


Figura 51: Relação entre *tweets* classificados como negativos e a variação do preço da Dogecoin

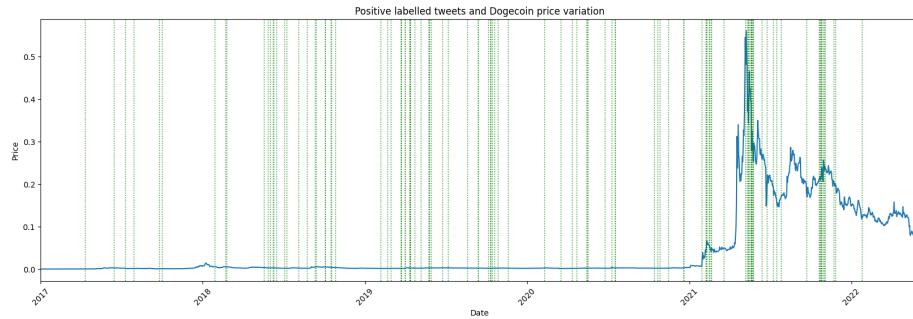


Figura 52: Relação entre *tweets* classificados como positivos e a variação do preço da Dogecoin

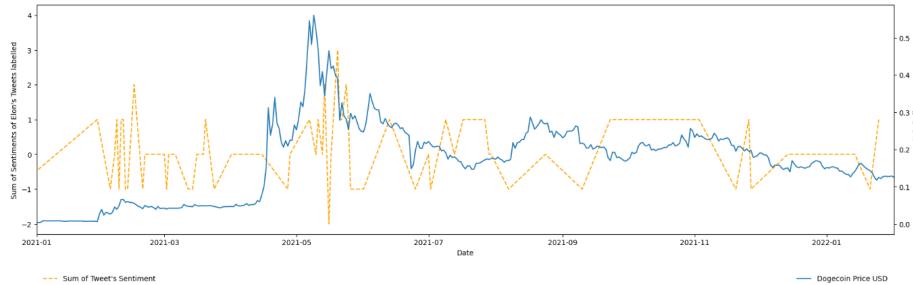


Figura 53: Relação entre o número de *tweets* de Elon Musk e a variação do preço da Dogecoin

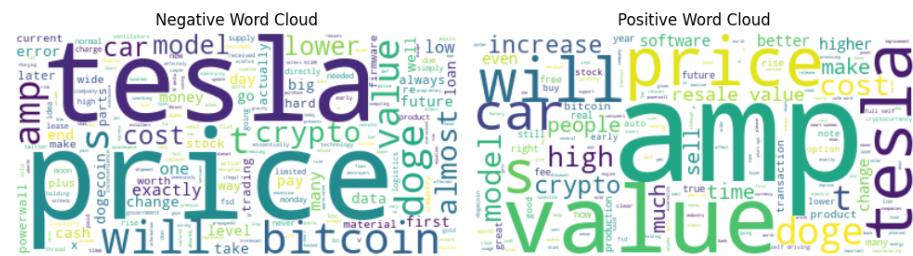


Figura 54: Distribuição positiva e negativa dos diferentes termos